

Universidade Federal do Sul e Sudeste do Pará Faculdade de Computação e Engenharia Elétrica Inteligência Artificial

Aula 15 - Capítulo 5: Pré-Processamento de Dados

Prof. Dr. Elton Alves

Introdução

- □O desempenho de um algoritmo de Aprendizagem de Máquina depende do <u>estado dos dados</u>.
- □Estado do dado:
- Ruidosos
- Contém erros, ou valores diferentes do esperado.
- **OIncompletos**
- Atributos faltosos
- ☐ Técnicas de pré-processamento de dados melhoram a qualidade dos dados.

□Dados incompletos - ausência de valores.

Idade	Sexo	Peso	Manchas	temp	#Int	Diagnostico
	M	79	_	38	_	doente
18	F	67	inexistente	39,5	4	doente
49	M	92	espalhadas	38	2	saúdavel
18	_	43	inexistente	38,5	8	doente
21	F	52	uniforme	37,6	1	saúdavel
22	F	72	inexistente	38	3	doente
_	F	87	espalhadas	39	6	doente
34	M	67	uniforme	38,2	2	saúdavel

□Soluções:

- OEliminar os objetos ausentes;
- OPreencher manualmente.
- oEtc.

□Dados inconsistentes – valores conflitantes em seus atributos.

Idade	Sexo	Peso	Manchas	temp	#Int	Diagnostico
_	М	79	_	38	_	doente
18	F	67	inexistente	39,5	4	doente
49	M	92	espalhadas	38	2	saúdavel
18	_	43	inexistente	38,5	8	doente
21	F	52	uniforme	37,6	1	saúdavel
22	F	72	inexistente	38	3	doente
_	F	87	espalhadas	39	6	doente
22	F	72	uniforme	38	3	saúdavel

□Solução:

○ Remoção

□Dados redundantes – um objeto é redundante quando ele é muito semelhante a um outro objeto do mesmo conjunto de dados.

Idade	Sexo	Peso	Manchas	temp	#Int	Diagnostico
28	M	79	_	38	_	doente
18	F	67	inexistente	39,5	4	doente
49	M	92	espalhadas	38	2	saúdavel
18	F	43	inexistente	39,5	4	doente
21	F	52	uniforme	37,6	1	saúdavel
22	F	72	inexistente	38	3	doente
_	F	87	espalhadas	39	6	doente
22	F	72	uniforme	38	3	saúdavel

□Solução:

○Eliminação

□ Dados com ruídos – não pertencem á distribuição que gerou os dados analisados (*outliers*).

Idade	Sexo	Peso	Manchas	temp	#Int	Diagnostico
28	M	79	_	38	_	doente
18	F	300	inexistente	39,5	4	doente
49	M	92	espalhadas	38	2	saúdavel
18	F	43	inexistente	39,5	4	doente
21	F	52	uniforme	37,6	1	saúdavel
22	F	72	inexistente	38	3	doente
_	F	87	espalhadas	39	6	doente
22	F	72	uniforme	38	3	saúdavel

□Solução: Remoção do ruído (suavização) e Identificação de valores discrepantes (clusterização)

Transformação de Atributos Numéricos

□Normalização dos dados — grande diferença dos limites dos valores dos atributos distintos (predominância de atributos).

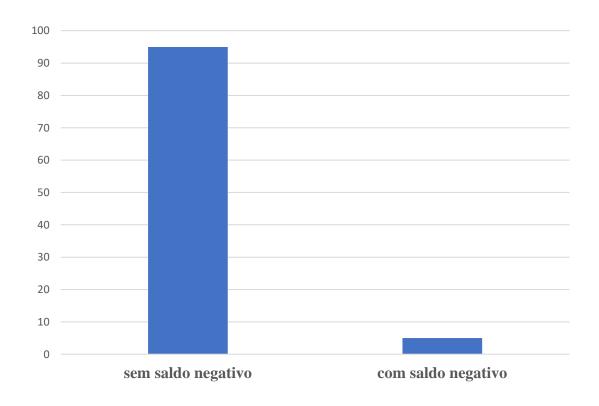
$$v_{novo} = min + \frac{v_{atual} - menor}{maior - menor}(max - min)$$

Dados desbalanceados

□Exemplo: conjunto de dados de clientes de um banco.

Classe majoritária: 95% sem saldo negativo.

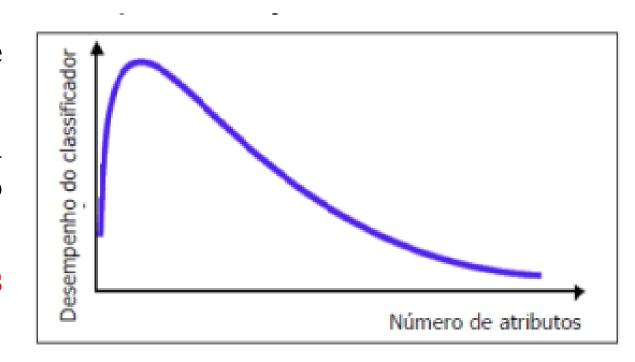
OClasse minoritária: 5% com saldo negativo.



Solução: Técnicas de balanceamento de dados sintéticos - SMOTE.

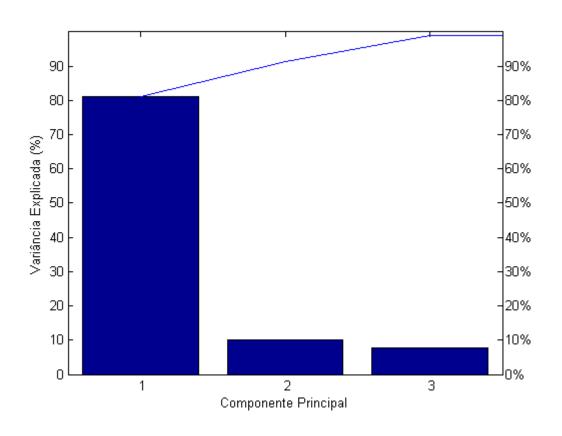
Redução de Dimensionalidade

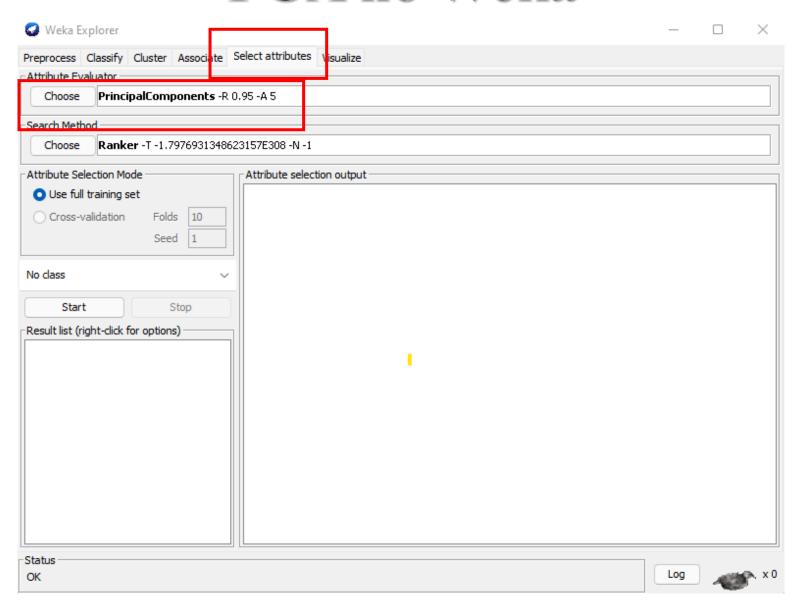
- □ Problemas com elevado número de atributos.
- □Redução de atributos podem melhorar o desempenho do modelo induzido.
- ☐ Análise de Componentes Principais (PCA).



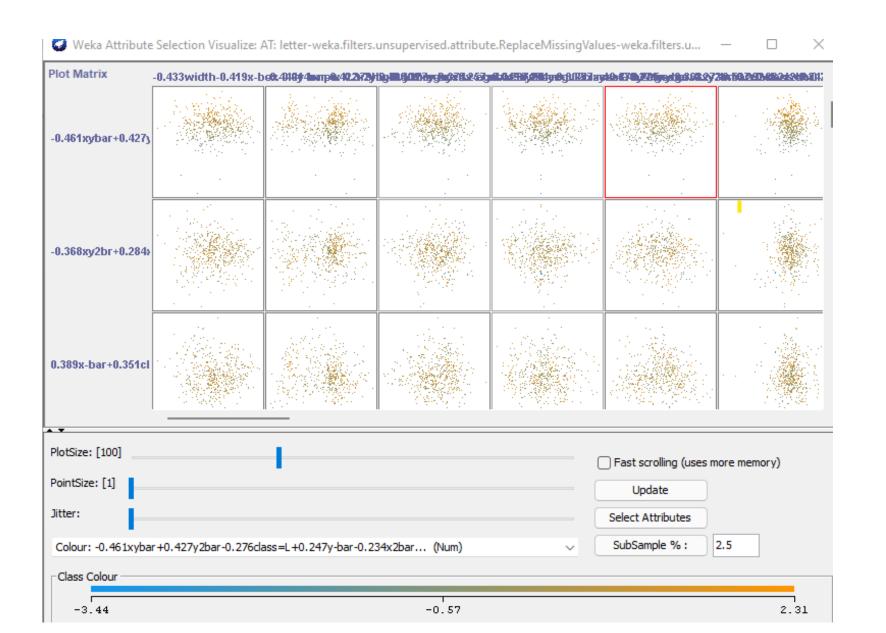
Análise de Componentes Principais (PCA)

- Consiste na <u>transformação</u> dos dados para um novo espaço com dimensão inferior ao original.
- O novo espaço fica caracterizado por um novo conjunto de eixos, ortonormais entre si, ordenados em ordem <u>decrescente de variância</u>.





```
Ranked attributes:
          1 -0.433width-0.419x-box-0.414onpix-0.379high-0.377y-box...
0.8949
                                                                              Variância Explicada
0.8143
          2 -0.449v-bar-0.422x2vbr-0.409xeqvv+0.257x-bar+0.244veqvx...
0.7574
          3 0.49 v2bar-0.374x-ege-0.287x2bar+0.277xvbar+0.271v-ege...
0.7088
          4 0.445xv2br+0.302class=C-0.295xvbar-0.273x-bar+0.262x2bar...
          5 -0.372v-ege+0.368xy2br-0.292class=P-0.284class=B+0.245class=J...
0.6682
          6 -0.537class=L+0.347xybar+0.34 x-bar+0.304yeqvx+0.3 class=J...
0.631
          7 0.484x2bar+0.31 class=U-0.299class=W+0.239class=J+0.239xvbar...
0.5971
0.5651
          8 0.386class=M-0.297class=L+0.292class=Z-0.288class=P+0.24 y2bar...
0.534
          9 0.337class=K+0.327class=F-0.326class=Y-0.317x-bar+0.281class=R...
0.5067
         10 0.348class=R+0.343class=T+0.324class=V-0.295class=W+0.287class=T...
         11 -0.465class=W+0.385class=F+0.317class=A-0.266class=D-0.247class=N...
0.4802
         12 0.509class=T+0.394class=N-0.333class=U-0.307class=B+0.264class=R...
0.4541
0.4287
         13 0.443class=0-0.405class=X+0.403class=I-0.291class=V+0.221class=F...
0.4037
         14 0.457class=H-0.454class=S-0.325class=I-0.317class=N-0.256class=O...
0.3788
         15 0.379class=X+0.365class=O-0.361class=T+0.325class=Z+0.278class=N...
0.354
         16 0.651class=D-0.353class=U-0.348class=P+0.25 class=V+0.225class=F...
0.3292
         17 -0.416class=U+0.408class=Y+0.394class=M-0.331class=O-0.254class=F...
0.3045
         18 -0.442class=P-0.385class=E+0.345class=B+0.271class=F+0.236class=J...
0.2797
         19 -0.57class=G+0.401class=E+0.319class=N-0.242class=T+0.232class=Y...
         20 0.505class=R-0.419class=B+0.36 class=Y-0.31class=V+0.212class=U...
0.2549
0.2302
         21 0.507class=0+0.43 class=X-0.371class=N-0.35class=G-0.284class=Z...
0.2054
         22 0.526class=Z-0.348class=X-0.347class=G+0.333class=V-0.286class=E...
0.1807
         23 -0.409class=C+0.354class=E-0.33class=B-0.306class=K+0.303class=V...
```



Atributos selecionados

